

# A5: Simulering af x86prime - x86\_64 delmængde med udvidelser

Computer Systems 2021  
Department of Computer Science  
University of Copenhagen

Finn Schiermer Andersen

**Due:** Søndag, 19. December, 16:00  
**Version 1**

Dette er den sjette afleveringsopgave i Computersystemer og den første som dækker Maskinarkitektur. Som tidligere, opfordrer vi til par-programmering og anbefaler derfor at lave grupper af 2 til 3 studerende. Grupper må ikke være større end 3 studerende og vi advarer mod at arbejde alene.

Afleveringer vil blive bedømt med op til 4 point. Du skal opnå mindst halvdelen af mulige point over kurset for at blive indstillet til eksamen, samt 40 % inden for hvert underemne. Du kan finde yderligere detaljer under siden "Course description" på Absalon. Denne aflevering hører under Maskinarkitektur. Det er *ikke* muligt at genaflevere afleveringer.

## Introduction

*There is only one mistake that can be made in a computer design that is difficult to recover from – not providing enough address bits for memory addressing and memory management.*

— Gordon Bell, *Computer Structures: What Have We Learned from the PDP11?*  
(1976)

Denne afleveringsopgave består i at færdiggøre en simulator for et mindre instruktionssæt, defineret over assembler sproget vi kalder *x86prime*. X86prime er i overvejende grad en delmængde af x86\_64 assembler sproget, men der er også enkelte instruktioner i x86prime som ikke indgår i x86\_64.

Til løsning af opgaven udleverer vi en halvfærdig simulator som kun kan udføre nogle få forskellige instruktioner. Det er denne simulator der skal færdiggøres og testes; dertil skal arbejdet dokumenteres i jeres rapport.

Dertil skal der også løses en teoretisk opgave, som findes i Afsnit 4.

## 1 Assembler sproget x86prime

Som nævnt er x86prime defineret som en delmængde af x86\_64, som beskrevet i BOH. Grunden til at vi i denne opgave ikke benytter x86\_64, er at assembler sproget (og det tilhørende instruktionssæt) er alt for stort og har en for kompleks semantik til at I kan forstå og bygge simulator over opgaveforløbet.

x86prime er dog valgt så det dækker mange af de mest brugte instruktioner fra x86\_64 og uvidelserne har simple program transformationer til/fra x86\_64. Forståelse af x86\_64 giver derfor en forståelse af x86prime og vice versa.

Til x86prime bruger vi følgende delmængde af x86\_64 instruktionerne:

- `MOVQ %ra, %rb`: kopiering fra et register til et andet,
- `MOVQ $imm, %rb`: initialisering af register,
- `MOVQ $imm(%rb), %ra`: læsning fra lageret,
- `MOVQ %ra, $Imm(%rb)`: skrivning til lageret,
- `ADDQ/SUBQ/ANDQ/ORQ/XORQ/MULQ/IMULQ/SAR/SAL/SHR %ra, %rb`: aritmetik på registre,
- `ADDQ/SUBQ/ANDQ/ORQ/XORQ/MULQ/IMULQ/SAR/SAL/SHR $imm, %rb`: aritmetik med heltal,
- `JMP target`: ubetinget hop,
- `LEAQ $imm(%rs,%rz,$scale), %ra`.

Læg mærke til at `MOVQ` instruktioner *kun* giver mulighed for ét adresseberegnings register, samt *ikke* har mulighed for at skalere det ene.

Dertil udvider vi med følgende instruktioner som ikke er originale x86 instruktioner:

- `CALL target, %ra`: underprogramkald som gemmer returadressen i %ra,
- `STOP`: stop simulationen,
- `RET %ra`: retur fra underprogramkald som læser returadressen fra %ra,
- `CBcc %ra, %rb, target`: hop hvis relationen %ra cc %rb er opfyldt,
- `CBcc $imm, %rb, target`: hop hvis relationen \$imm cc %rb er opfyldt.

Forskellen i ovenstående til x86\_64 er at kald til og returnering fra procedurer håndteres ved at gemme/hente returadressen fra et register og *ikke* kaldstakken; som generel konvention vil vores oversættelse af C og x86\_64 kode benytte %r11 til dette. Dertil benytter x86prime ikke betingelsesflag til at foretage betingede hop, men sammensætter både test og hop i instruktionen `CBcc`.

En anden ændring er at x86prime benytter en anden indkodning af ordrer end x86\_64; altså en anden oversættelse fra assembler sprog til maskinkode. Dette er igen for at gøre opgaven nemmere for jer. Instruktionerne og indkodningen er nærmere beskrevet i filen `encoding.txt`, som ligger sammen med den udleverede kildetekst, og vist i Bilag A.

Du finder en introduktion til x86prime her:

<https://x86prime.github.io/x86prime/>

## 2 Hjelpeværktøjer

Til hjælp med at arbejde med x86 prime, udleverer vi programmerne, `prasm` og `prun`, der fungerer som hhv. assembler og reference-simulator:

`prasm` indkoder x86prime assembler programmer til et hexadecimalt format, som kan indlæses af den udleverede halvfærdige simulator.

`prun` simulerer x86prime programmer og generere en "sporningsfil". Denne fil kan indlæses af den udleverede halvfærdige simulator, hvor den kan bruges til at holde den ufærdige simulators opførsel op imod reference-simulatoren.

Du finder kildeteksten på GitHub her:

<https://github.com/finnschiermer/x86prime>

Du er velkommen til selv at oversætte værktøjet lokalt på din maskine, men eventuelle problemer du oplever må du selv løse<sup>1</sup>. Vi frigiver et "image" til en virtual maskine hvor værktøjet er pre-installeret og har de nødvendige biblioteker til oversættelse.

## 3 Kildetekst til simulator


Vi udleverer en halvfærdig simulator som kan udføre følgende instruktioner:

- STOP
- Aritmetiske instruktioner som arbejder på registre (ikke lageret)
- MOVQ fra et register til et andet
- LEAQ (s),d dvs den simpleste form af LEAQ instruktionen.

Den halvfærdige simulator finder du i en zip-fil der distribueres sammen med denne opgavetekst.

For at færdiggøre simulatoren er det nødvendigt at lave tre forbedringer

- Længden af hver instruktion skal bestemmes. Den udleverede simulator antager slet og ret at alle instruktioner er 2 bytes. Derfor vil den hurtigt gå galt i byen, hvis den møder en instruktion med en anden længde.
- Instruktioner som tilgår lageret skal bringes til at virke korrekt. Den udleverede simulator foretager en del af afkodningen, men resten skal implementeres.
- Instruktioner som ændrer afviklingen af programmet (JMP, RET, CALL, CBcc) skal implementeres. Den udleverede simulator kan kun udføre en sekvens af fortløbende instruktioner.



**Figure 1:** Diagram som viser datavejen for en simpel enkelt-cyklus processor. En sort prik indikerer at linien bliver delt til flere enheder.

Til hjælp findes i Figur 1 et forslag til en datavej der kan bringes til at udføre alle de ønskede instruktioner. Det er ikke et krav at simulatoren implementerer præcis denne datavej, men variationer bør argumenteres for i rapporten.

Den halvferdige simulator består af følgende filer:

- `main.c` - Hovedprogram. Du behøver kun at rette i denne fil for at løse opgaven.
- `wires.h`, `wires.c` - Funktioner der implementerer til forbindelser/ledninger på en processor.
- `arithmetic.h`, `arithmetic.c` - Funktioner der bruges til grundlæggende aritmetik og digital logik.
- `compute.h`, `compute.c` - Diverse regneenheder der passer til x86prime.
- `memory.h`, `memory.c` - Lageret (Main memory).
- `registers.h`, `registers.c` - Registerfilen.
- `ip_reg.h`, `ip_reg.c` - IP-registeret (Program Counter).

<sup>1</sup>Brug forum for kurset til at bede om hjælp til at løse problemer. Der er en sandsynlighed for at en medstuderende kender til det.

### 3.1 Byggeklodser

Den halvfærdige simulator skal færdiggøres. I skal bruge sproget 'C' til at bygge en simulator som emulerer en faktisk elektronisk processor. Vi sætter nogle begrænsninger på hvordan I må bruge 'C' til denne implementation. Disse begrænsninger tvinger jer til at bruge 'C' som om det var en form for hardware-beskrivelses-sprog fremfor et generelt anvendeligt programmeringssprog. De begrænsninger vi vælger vil virke snærende, men de er essentielle for at sikre forståelse af hvordan maskinen virker og er opbygget.

Der er nogle ting I gerne må bruge:

- I må gerne bruge de udleverede funktioner. Disse er "byggeklodser" til at lave simuleringen med.
- I må gerne bruge variabler af typen `bool` og `val`. Disse fungerer som "ledninger" i simulationen.
- I må gerne bruge Boolsk logik (`||`, `&&` ovs.), men kun på variable af typen `bool`. Disse fungerer som logiske porte.

Og nogle ting I *ikke* må bruge:

- I må ikke arbejde med 64-bit værdier direkte. I skal bruge typen `val`, samt de udleverede funktioner der arbejder på værdier af denne type.
- I må ikke bruge conditionals (`if`, `else`, `?`-operatoren).
- I må ikke bruge løkker (`for`, `while`) udover hovedløkken der allerede er skrevet.
- I må ikke sætte en variabls værdi mere end én gang. Hver variabel repræsenterer en elektrisk leder (eller flere) og sådanne kan kun lede et stabilt signal i løbet af en given maskin-cyklus. Dette kender I fra implementationer i F#

De ting I ville gøre med conditionals kan typisk gøres med funktioner fra `wires.h`.

For at løse opgaven er det tilstrækkeligt at ændre/tilføje til koden i `main()` i filen `main.c`. De steder i filen, hvor der skal ændres er markeret med "TODO: 2021!"

## 4 Teoretisk opgave

Nedenfor er givet 2 funktioner i x86prime maskinsprog.

```
.LFB0:
    subq $8, %rsp
    movq %r11, (%rsp)
    movq $0, %eax
.L2:
    cble %rdx, %rax, .L4
    leaq (%rsi, %rax, 8), %r11
```

```
movq (%r11), %rcx
movq (%rcx), %rcx
leaq (%rdi, %rax, 8), %r11
movq %rcx, (%r11)
addq $1, %rax
jmp .L2
.L4:
movq (%rsp), %r11
addq $8, %rsp
ret %r11
```

Og

```
.LFB1:
subq $8, %rsp
movq %r11, (%rsp)
leaq (%rdi, %rcx, 8), %r8
jmp .L6
.L7:
movq %rax, (%rdi)
.L8:
addq $8, %rdi
addq $8, %rsi
addq $8, %rdx
.L6:
cbbe %r8, %rdi, .L10
movq (%rsi), %rcx
movq (%rdx), %rax
cbge %rax, %rcx, .L7
movq %rcx, (%rdi)
jmp .L8
.L10:
movq (%rsp), %r11
addq $8, %rsp
ret %r11
```

Besvar følgende spørgsmål for hver funktion/kodestump:

- 4.1. Angiv for hver register om det bruges til at holde en pointer eller en long
- 4.2. Udpeg de instruktioner som implementerer kald og retur
- 4.3. Beskriv programforløbet - identificer betinget kode, løkker og eventuelle kald af andre funktioner
- 4.4. Find og beskriv de betingelser som bestemmer eventuel betinget kode eller løkker
- 4.5. Opstil en C kildetekst der svarer til funktionen.

## 5 Bedømmelse og vejledning

De forskellige dele af afleveringen bliver vurderet efter følgende:

- 10% for en løsning der korrekt bestemmer længden af samtlige instruktioner, inklusiv test af dette.
- 15% for en løsning der korrekt udfører instruktioner som læser fra eller skriver til lageret, inklusiv test af disse.
- 25% for en løsning der korrekt udfører `JMP`, `RET`, `CALL` og `CBcc`, inklusiv test af disse.
- 35% Rapport som dokumenterer jeres implementation. Husk en rapport inkluderer:
  - Beskrivelse af hvordan jeres kode oversættes og hvordan jeres tests skal køre for at genskabe jeres resultater.
  - Diskussion af alle ikke-trivielle dele af jeres implementation og design beslutninger.
  - Beskrivelse alle tvetydige formuleringer, som I kan have fundet i opgave teksten.
  - Generel test af de implementerede dele af simulatores inklusiv tydeliggørelse af evt. mangler og afvigelser.
- 15% for løsning af den teoretiske opgave.

Det er forventeligt at rapporten er omkring 5 sider og den må ikke overskrive 7 sider.

For at få point skal man kunne dokumentere at opgaven er løst korrekt. Det gøres ved at udarbejde og køre testprogrammer og bekræfte at den udarbejdede løsning laver de samme ændringer til lager og registre som reference-simulatoren. Overvej både test for specifikke instruktioner og sammenhængen mellem flere instruktioner.

Vi anbefaler at man løser opgaven i tre faser svarende til de tre første punkter ovenfor, da de er rangeret efter sværhedsgrad. På den måde ved man rimelig sikkert, hvornår et point er i hus. Det er så trist at få alt til at virke, og så ikke have tid til at teste det.

Sammen med jeres rapport, `report.pdf`, skal I aflevere en `src.zip` som indeholder jeres udviklede simulator og test programmer, samt en `group.txt`. `group.txt` skal ASCII/UTF8 formateret liste KU-id'er fra alle medlemmer i gruppen; et id pr. line, ved brug af følgende tegnsæt:

$$\{0x0A\} \cup \{0x30, 0x31, \dots, 0x39\} \cup \{0x61, 0x62, \dots, 0x7A\}$$

## A encoding.txt

x86prime instructions and encoding

-----

Encoding:	Assembler	Operation
00000000 00000000	stop	stop the machine
00000001 0000ssss	ret s	return from function call
0001aaaa ddddssss	op s,d	reg/reg arithmetic (see below)
00100001 ddddssss	movq s,d	reg->reg copy
00110001 ddddssss	movq (s),d	load (memory -> reg copy)
00111001 ddddssss	movq d,(s)	store (reg -> memory copy)
-		
0100cccc ddddssss pp...32...pp	cb<c> s,d,p	compare and continue at p if... (see below)
01001110 dddd0000 pp...32...pp	call p,d	function call
01001111 00000000 pp...32...pp	jmp p	continue at p
0101aaaa dddd0000 ii...32...ii	op \$i,d	constant/reg arithmetic(see below)
01100100 dddd0000 ii...32...ii	movq \$i,d	constant -> register
01110101 ddddssss ii...32...ii	movq i(s),d	load (memory -> reg copy)
01111101 ddddssss ii...32...ii	movq d,i(s)	store (reg -> memory copy)
-		
10000001 ddddssss	leaq (s),d	s -> d
10010010 dddd0000 zzzzvwww	leaq (,z,v),d	z*v -> d
10010011 ddddssss zzzzvwww	leaq (s,z,v),d	s+z*v -> d
10100100 dddd0000 ii...32...ii	leaq i,d	i -> d
10100101 ddddssss ii...32...ii	leaq i(s),d	i+s -> d
10110110 dddd0000 zzzzvwww ii...32...ii	leaq i(,z,v),d	i+z*v -> d
10110111 ddddssss zzzzvwww ii...32...ii	leaq i(s,z,v),d	i+s+z*v -> d
-		
1111cccc dddd0000 ii...32...ii pp...32...pp cb<c> \$i,d,p		compare and continue at p if... (see below)

Note: first 4 bits are called the "major opcode", next 4 bits are called the "minor opcode".

Explanations:

aaaa indicates the kind of arithmetic operation. All operate on full 64 bits:

```

0000 add  addition
0001 sub  subtraction
0010 and  bitwise and
0011 or   bitwise or
0100 xor  bitwise xor
0101 mul  unsigned multiplication
0110 sar  shift arithmetic right (preserve topmost bit)
0111 sal  shift arithmetic left (zero into lsb, do not preserve topmost bit)
1000 shr  shift (logical) right (zero into topmost bit)
1001 imul signed multiplication

```

d,s and z are registers:

```

0000 %rax    1000 %r8

```



0001 %rbx	1001 %r9
0010 %rcx	1010 %r10
0011 %rdx	1011 %r11
0100 %rbp	1100 %r12
0101 %rsi	1101 %r13
0110 %rdi	1110 %r14
0111 %rsp	1111 %r15

v is a scale factor encoded into the field vvvv in the form of a shift amount as follows:

vvvv v
0000 1
0001 2
0010 4
0011 8

ii...32...ii is a 32 bit signed immediate

pp...32...pp is a 32 bit target address

<c> is a condition mnemonic used in compare-and-branch. The compare-and-branch instruction cb<c> is not part of the original x86 instruction set, but the conditions in x86prime carry the same meaning as for x86.

Example: cble %rdi,%rbp,target      = if %rdi <= %rbp (signed) then jump to target

Encoding	Semantic
0000 e	Equal
0001 ne	Not equal
0010 <reserved>	
0011 <reserved>	
0100 l	less (signed)
0101 le	less or equal (signed)
0110 g	greater (signed)
0111 ge	greater or equal (signed)
1000 a	above (unsigned)
1001 ae	above or equal (unsigned)
1010 b	below (unsigned)
1011 be	below or equal (unsigned)
11xx <reserved>	

Note that signed and unsigned comparisons are different.

call places the return address in a register instead of pushing it onto the stack.

ret returns to the address in a register instead of popping it from the stack.

returning to address 0 or to a negative address (bit 64 set) stops the machine.